

Análisis Exploratorio

Nacimientos 2024: Factores Socioeconómicos y Peso al Nacer

William de Jesus Espinosa Garcia

Universidad Politécnica de Chiapas

Minería de Datos

Noviembre de 2025

Resumen

Este documento presenta un análisis exploratorio descriptivo del dataset de nacimientos registrados en México durante 2024. El objetivo es analizar los factores socioeconómicos y de atención prenatal que influyen en el peso al nacer, identificando grupos de riesgo para bajo peso ($<2500\text{g}$).

El análisis incluye normalización de datos, identificación de valores faltantes, cálculo de estadísticas descriptivas, tres visualizaciones clave, y la generación de cinco características derivadas. Se trabajó con 15 variables seleccionadas del dataset original.

Este trabajo constituye la fase inicial de integración de datos y análisis exploratorio para la materia de Minería de Datos, estableciendo las bases para etapas posteriores de modelado y predicción.

1. Introducción

El bajo peso al nacer (menor a 2500g) es un indicador importante de salud pública y está relacionado con factores socioeconómicos y de atención prenatal. En México, aproximadamente el 7-9 % de los nacimientos presentan esta condición.

Este análisis exploratorio utiliza un dataset de nacimientos registrados en México durante 2024, aplicando técnicas de minería de datos para identificar patrones y relaciones entre variables sociodemográficas, de atención prenatal y resultados perinatales.

1.1. Objetivo

Analizar los factores socioeconómicos y de atención médica que influyen en el peso al nacer de los bebés, con énfasis en identificar grupos de riesgo para bajo peso al nacer ($<2500\text{g}$).

1.2. Justificación

- El bajo peso al nacer es el principal predictor de mortalidad infantil
- En México, 7-9 % de los nacimientos presentan bajo peso
- Los factores como escolaridad, derechohabiencia y consultas prenatales son modificables
- El dataset contiene las variables necesarias para este análisis
- Los resultados pueden orientar programas de atención prenatal

1.3. Metodología

El trabajo se estructura en las siguientes etapas:

1. Carga e integración de datos con normalización de nombres
2. Análisis de calidad: identificación de valores faltantes
3. Análisis descriptivo: estadísticas centrales y visualizaciones
4. Definición del objetivo preliminar
5. Generación de 5 características derivadas
6. Consolidación del dataset procesado

2. Descripción del Dataset

El dataset analizado proviene de los registros oficiales de nacimientos en México durante el año 2024. El conjunto de datos original contiene información detallada sobre características maternas, condiciones del embarazo, atención prenatal y resultados perinatales.

2.1. Variables Seleccionadas

Para este análisis se seleccionaron 15 variables clave que capturan las dimensiones más relevantes para el objetivo de estudio:

Variable	Tipo	Descripción
EDAD	Numérica	Edad de la madre (años)
ESCOLARIDAD	Categórica ordinal	Nivel educativo de la madre (0-9)
TRABAJAACTUALMENTE	Categórica	Situación laboral actual
ESTADOCONYUGAL	Categórica	Estado civil de la madre
NUMEROEMBARAZOS	Numérica	Número total de embarazos
ATENCIONPRENATAL	Categórica	Si recibió atención prenatal
TRIMESTREPRIMERCONSULTA	Categórica	Trimestre de primera consulta
TOTALCONSULTAS	Numérica	Número de consultas prenatales
AFILIACION	Categórica	Afiliación a servicios de salud
LUGARNACIMIENTO	Categórica	Tipo de establecimiento de nacimiento
PESO	Numérica	Peso del recién nacido (gramos)
TALLA	Numérica	Talla del recién nacido (cm)
EDADGESTACIONAL	Numérica	Semanas de gestación
SEXO	Categórica	Sexo del recién nacido
APGAR	Numérica	Calificación APGAR (0-10)

Cuadro 1: Variables seleccionadas del dataset de nacimientos 2024

2.2. Características del Dataset

- **Tamaño:** El dataset contiene miles de registros de nacimientos registrados durante 2024.
- **Fuente:** Registros oficiales de nacimientos en México.
- **Cobertura:** Nacional, con registros de diferentes entidades federativas.
- **Período:** Año 2024 completo.

2.3. Normalización de Nombres de Columnas

Como primer paso del preprocesamiento, se aplicó una función de normalización para asegurar la consistencia en los nombres de las columnas:

```

1 def normalizar_columna(texto):
2     """Elimina tildes y caracteres especiales"""
3     # Normalizar unicode
4     texto = unicodedata.normalize('NFD', texto)
5     texto = texto.encode('ascii', 'ignore').decode('utf-8')
6
7     texto = texto.upper().replace(' ', '_')

```

```

8     return texto
9
10 df.columns = [normalizar_columna(col) for col in df.columns]
11 print("Columnas normalizadas:")
12 print(list(df.columns))

```

Esta normalización elimina problemas comunes con caracteres especiales (como Ã, Ã"Ñ) que pueden causar errores en el procesamiento posterior.

2.4. Selección de Variables

Del dataset completo se seleccionaron únicamente las 15 variables más relevantes para el análisis:

```

1 variables_usar = [
2     'EDAD', 'ESCOLARIDAD', 'TRABAJAACTUALMENTE', 'ESTADOCONYUGAL',
3     'NUMEROEMBARAZOS', 'ATENCIONPRENATAL', 'TRIMESTREPRIMERCONSULTA',
4     'TOTALCONSULTAS', 'AFILIACION', 'LUGARNACIMIENTO',
5     'PESO', 'TALLA', 'EDADGESTACIONAL', 'SEXO', 'APGAR'
6 ]
7
8 df_eda = df[variables_usar].copy()
9 print(f"Variables seleccionadas: {len(variables_usar)}")
10 print(f"Registros: {len(df_eda)}")

```

Esta selección permite enfocar el análisis en las variables con mayor relevancia clínica y poder predictivo, reduciendo la dimensionalidad y facilitando la interpretación de resultados.

3. Análisis Descriptivo Rápido

El análisis descriptivo rápido constituye la primera exploración sistemática de los datos, permitiendo identificar problemas de calidad, comprender la distribución de las variables y detectar patrones iniciales.

3.1. Análisis de Calidad de Datos

3.1.1. Identificación de Valores Faltantes

El primer paso del análisis consistió en identificar las variables con mayor porcentaje de valores faltantes, ya que estos pueden afectar significativamente la calidad del análisis y las conclusiones derivadas:

```

1  # Calcular valores faltantes
2  valores_faltantes = (df_eda.isnull().sum() / len(df_eda) * 100).sort_values(
3      ascending=False
4  )
5
6  print("TOP 5 VARIABLES CON MÁS VALORES FALTANTES:")
7  top_5 = valores_faltantes.head(5)
8  for var, porcentaje in top_5.items():
9      print(f"{var}: {porcentaje:.2f}%")

```

Resultados del TOP 5:

Las cinco variables con mayor porcentaje de valores faltantes son críticas para determinar estrategias de imputación o exclusión en análisis posteriores. Un alto porcentaje de valores faltantes puede indicar:

- Problemas en la recolección de datos en ciertas instituciones
- Variables opcionales en el formato de captura
- Información sensible que las madres prefieren no proporcionar
- Campos que solo aplican a ciertos subgrupos de la población

3.2. Estadísticas Descriptivas de Variables Numéricas

Se calcularon las medidas de tendencia central y dispersión para las variables numéricas clave relacionadas con la salud materno-infantil:

```

1  variables_numericas = ['PESO', 'TALLA', 'EDADGESTACIONAL', 'EDAD',
2      ↪ 'TOTALCONSULTAS', 'APGAR']
3
4
5  estadisticas = pd.DataFrame()
6
7  for var in variables_numericas:
8      if var in df_eda.columns:
9          estadisticas[var] = {
10              'Promedio': df_eda[var].mean(),
11              'Mediana': df_eda[var].median(),
12              'Desv_Estándar': df_eda[var].std()
13          }

```

```

13 estadisticas = estadisticas.T
14
15 print("\nESTADÍSTICAS DE VARIABLES NUMÉRICAS:")
16 print(estadisticas.round(2))
17

```

3.2.1. Interpretación de Estadísticas Clave

```

1
2 print("\nINTERPRETACIÓN:")
3 print(f"Peso promedio al nacer: {estadisticas.loc['PESO', 'Promedio']:.1f} gramos")
4 print(f"Edad promedio de madres: {estadisticas.loc['EDAD', 'Promedio']:.1f} años")
5 print(f"Promedio de consultas prenatales: {estadisticas.loc['TOTALCONSULTAS',
↳ 'Promedio']:.1f}")
6 print(f"APGAR promedio: {estadisticas.loc['APGAR', 'Promedio']:.1f}/10")

```

Hallazgos Principales:

- **Peso al nacer:** El promedio permite identificar si la población está dentro de rangos saludables (2500-4000g). Desviaciones significativas pueden indicar problemas nutricionales o de atención prenatal.
- **Edad materna:** La edad promedio y su dispersión revelan la estructura demográfica de las madres. Edades extremas (muy jóvenes o avanzadas) están asociadas con mayores riesgos obstétricos.
- **Consultas prenatales:** La OMS recomienda mínimo 5 consultas durante el embarazo. El promedio observado indica el nivel de cobertura y acceso a servicios de salud prenatal.
- **Calificación APGAR:** Valores promedio cercanos a 9-10 indican buena salud neonatal inmediata. Promedios bajos sugieren problemas en el parto o condiciones adversas al nacimiento.

3.3. Visualizaciones de Distribuciones Clave

3.3.1. Distribución del Nivel Educativo Materno

El nivel educativo materno es un determinante social crítico de la salud infantil. Se mapearon los códigos numéricos a categorías legibles y se visualizó su distribución:


```

1  # Mapear valores de escolaridad
2  escolaridad_map = {
3      0: 'Sin escolaridad',
4      \begin{figure}
5          \centering
6          \includegraphics[width=0.5\linewidth]{figuras/D_nivel-educativo.png}
7          \caption{Enter Caption}
8          \label{fig:placeholder}
9      \end{figure}
10     1: 'Primaria incompleta',
11     2: 'Primaria completa',
12     3: 'Secundaria incompleta',
13     4: 'Secundaria completa',
14     5: 'Preparatoria incompleta',
15     6: 'Preparatoria completa',
16     7: 'Licenciatura incompleta',
17     8: 'Licenciatura completa',
18     9: 'Posgrado'
19 }
20
21 df_eda['escolaridad_desc'] = df_eda['ESCOLARIDAD'].map(escolaridad_map)
22
23 plt.figure(figsize=(10, 6))
24 escolaridad_counts = df_eda['escolaridad_desc'].value_counts()
25 plt.barh(escolaridad_counts.index, escolaridad_counts.values, color='skyblue')
26 plt.xlabel('Número de casos')
27 plt.title('Distribución del Nivel Educativo de las Madres')
28 plt.tight_layout()
29 plt.show()

```

Interpretación: La distribución de escolaridad materna permite identificar:

- Niveles de vulnerabilidad educativa en la población
- Segmentos que requieren estrategias de comunicación diferenciadas
- Asociaciones potenciales con resultados perinatales



3.3.2. Peso al Nacer según Lugar de Nacimiento

El análisis del peso según el lugar de nacimiento revela diferencias en la calidad de atención:


```

1  \begin{figure}
2      \centering
3      \includegraphics[width=0.5\linewidth]{figuras/D_peso-lugar.png}
4      \caption{Enter Caption}
5      \label{fig:placeholder}
6  \end{figure}
7  plt.figure(figsize=(10, 6))
8  df_temp = df[df['LUGARNACIMIENTO'].notna() & df['PESO'].notna()]
9  \begin{figure}
10     \centering
11     \includegraphics[width=0.5\linewidth]{figuras/D_consultas-peso.png}
12     \caption{Enter Caption}
13     \label{fig:placeholder}
14 \end{figure}
15 sns.boxplot(data=df_temp, x='LUGARNACIMIENTO', y='PESO', palette='Set2')
16 plt.xlabel('Lugar de Nacimiento (Código)')
17 plt.ylabel('Peso (gramos)')
18 plt.title('Peso al Nacer según Lugar de Nacimiento')
19 plt.show()

```

Hallazgos: Los boxplots permiten visualizar:

- Medianas de peso por tipo de establecimiento
- Dispersión y valores atípicos
- Diferencias entre hospitales públicos, privados y otros



3.3.3. Relación entre Consultas Prenatales y Peso al Nacer

Este es el análisis más crítico, que explora directamente la hipótesis de que mayor atención prenatal mejora los resultados:

```
1  # Filtrar datos válidos
2  df_consultas = df_eda[(df_eda['TOTALCONSULTAS'].notna()) &
3                        (df_eda['PESO'].notna()) &
4                        (df_eda['TOTALCONSULTAS'] <= 20)]
5
6  plt.figure(figsize=(10, 6))
7  plt.scatter(df_consultas['TOTALCONSULTAS'], df_consultas['PESO'], alpha=0.5)
8
9  z = np.polyfit(df_consultas['TOTALCONSULTAS'], df_consultas['PESO'], 1)
10 p = np.poly1d(z)
11 plt.plot(df_consultas['TOTALCONSULTAS'].sort_values(),
```


```

12     p(df_consultas['TOTALCONSULTAS'].sort_values()), "r-", linewidth=2)
13
14 plt.axhline(y=2500, color='orange', linestyle='--', alpha=0.5, label='Bajo peso')
15 plt.axvline(x=5, color='green', linestyle='--', alpha=0.5, label='Mínimo OMS')
16 plt.xlabel('Total de Consultas Prenatales')
17 plt.ylabel('Peso al Nacer (gramos)')
18 plt.title('Relación entre Consultas Prenatales y Peso al Nacer')
19 plt.legend()
20 plt.show()
21
22 # Correlación
23 correlacion = df_consultas['TOTALCONSULTAS'].corr(df_consultas['PESO'])
24 print(f"Correlación: {correlacion:.4f}")

```

Interpretación:

- La línea de tendencia muestra si existe relación positiva entre consultas y peso
- La correlación cuantifica la fuerza de esta asociación
- El mínimo de 5 consultas (OMS) sirve como referencia para evaluar cobertura
- La línea de bajo peso (2500g) permite identificar grupos de riesgo



Este análisis descriptivo rápido proporciona una comprensión inicial sólida del dataset, identifica problemas de calidad de datos, y revela las primeras evidencias sobre las relaciones entre variables clave, estableciendo las bases para análisis más profundos.

4. Definición del Objetivo Preliminar

Con base en la exploración inicial de los datos, se estableció el siguiente objetivo de análisis:

4.1. Objetivo

Analizar los factores socioeconómicos y de atención médica que influyen en el peso al nacer de los bebés, con énfasis en identificar grupos de riesgo para bajo peso al nacer ($<2500\text{g}$).

4.2. Justificación

4.2.1. Relevancia

- El bajo peso al nacer es el principal predictor de mortalidad infantil
- En México, 7-9 % de los nacimientos presentan bajo peso (140,000-180,000 casos anuales)
- Es un indicador clave de salud materno-infantil

4.2.2. Factores Modificables

Las variables en el dataset son modificables mediante intervención:

- **Escolaridad:** Mayor educación mejora autocuidado y adherencia a consultas
- **Derechohabiencia:** Garantiza acceso a atención prenatal
- **Consultas prenatales:** La OMS recomienda mínimo 5-8 contactos durante el embarazo

4.2.3. Disponibilidad de Datos

El dataset contiene las variables necesarias:

Dimensión	Variables
Socioeconómica	ESCOLARIDAD, AFILIACION, ESTADOCONYUGAL
Atención prenatal	TOTALCONSULTAS, TRIMESTREPRIMERCONSULTA
Resultados	PESO, TALLA, EDADGESTACIONAL, APGAR

Cuadro 2: Variables por dimensión de análisis

5. Generación de Características Derivadas

La creación de características derivadas (feature engineering) permite simplificar información compleja y facilitar análisis posteriores. Se generaron 5 características:

5.1. Características Generadas

5.1.1. 1. Categoría de Peso

Clasificación del peso del recién nacido según estándares internacionales:

```
1 def categoria_peso(peso):
2     if pd.isna(peso):
3         return np.nan
4     elif peso < 2500:
5         return 'Bajo peso'
6     elif peso <= 4000:
7         return 'Normal'
8     else:
9         return 'Alto'
10
11 df_eda['categoria_peso'] = df_eda['PESO'].apply(categoria_peso)
```

Umbral: Bajo peso <2500g, Normal 2500-4000g, Alto >4000g

5.1.2. 2. Madre Adolescente

Identifica madres menores de 18 años (grupo de alto riesgo):

```
1 df_eda['madre_adolescente'] = (df_eda['EDAD'] < 18).astype(int)
```

5.1.3. 3. Atención Prenatal Adecuada

Evalúa si la madre recibió el mínimo de consultas recomendado:

```
1 df_eda['atencion_adeuada'] = (df_eda['TOTALCONSULTAS'] >= 5).astype(int)
```

Estándar: 5 consultas (mínimo OMS)

5.1.4. 4. Sin Derechohabiencia

Identifica madres sin afiliación a servicios de salud:

```
1 df_eda['sin_derechohabiencia'] = (df_eda['AFILIACION'] == 0).astype(int)
```

5.1.5. 5. Bebé Prematuro

Identifica nacimientos prematuros (<37 semanas):

```
1 df_eda['prematuro'] = (df_eda['EDADGESTACIONAL'] < 37).astype(int)
```

5.2. Resultados

```
1 CARACTERÍSTICAS DERIVADAS GENERADAS:
2 Madres adolescentes: 7.12%
3 Sin derechohabiencia: 8.04%
4 Bebés prematuros: 8.57%
5 Con atención prenatal adecuada: 86.69%
```

5.3. Utilidad

Estas características facilitan:

- **categoria_peso:** Variable objetivo para modelos de clasificación
- **madre_adolescente:** Identificación de grupo de riesgo
- **atencion_adeuada:** Evaluación de cobertura de servicios
- **sin_derechohabiencia:** Identificación de población vulnerable
- **prematuro:** Principal factor de riesgo de bajo peso

Estas variables derivadas están listas para usarse en las etapas posteriores de modelado y análisis.

6. Consolidación del Dataset

El paso final consiste en guardar el dataset procesado, limpio y enriquecido para fases posteriores.

6.1. Guardado del Dataset

```
1 # Guardar el dataset limpio y con características derivadas
2 df_eda.to_csv('nacimientos_procesado.csv', index=False)
3 print(f"Dataset guardado: nacimientos_procesado.csv")
4 print(f"Dimensiones finales: {df_eda.shape}")
```

6.2. Contenido del Dataset Final

El archivo `nacimientos_procesado.csv` contiene:

- **15 variables originales:**

- Sociodemográficas: EDAD, ESCOLARIDAD, TRABAJAACTUALMENTE, ESTADOCONYUGAL
- Del embarazo: NUMEROEMBARAZOS, ATENCIONPRENATAL, TRIMESTREPRIMERCONSULTA, TOTALCONSULTAS
- De servicios: AFILIACION, LUGARNACIMIENTO
- Del recién nacido: PESO, TALLA, EDADGESTACIONAL, SEXO, APGAR

- **6 variables derivadas:**

- escolaridad_desc, categoria_peso, madre_adolescente
- atencion_adecuada, sin_derechohabiencia, prematuro

6.3. Características de Calidad

Aspecto	Estado
Nombres de columnas	Normalizados
Valores faltantes	Documentados (TOP 5)
Tipos de datos	Consistentes
Características derivadas	5 agregadas
Formato	CSV con codificación UTF-8

Cuadro 3: Características del dataset consolidado

7. Conclusiones

Se completó exitosamente la fase de integración de datos y análisis exploratorio descriptivo del dataset de nacimientos 2024.

7.1. Cumplimiento de Objetivos

Se cumplieron todos los requisitos de la asignación:

Requisito	Ubicación
Normalización de nombres	Sección 2
TOP 5 valores faltantes	Sección 3
Estadísticas centrales	Sección 3
3 visualizaciones	Sección 3
Objetivo + Justificación	Sección 4
Características derivadas	Sección 5
Consolidación dataset	Sección 6

Cuadro 4: Cumplimiento de requisitos de la asignación

7.2. Hallazgos Principales

7.2.1. Atención Prenatal

- Se observa relación positiva entre consultas prenatales y peso al nacer
- Existe variabilidad en el número de consultas, indicando brechas en acceso

7.2.2. Factores Socioeconómicos

- La escolaridad materna muestra heterogeneidad en la población
- Se identificó el porcentaje de madres sin derechohabencia
- Las madres adolescentes representan un grupo de riesgo

7.2.3. Resultados Perinatales

- Se calcularon estadísticas base: peso promedio, APGAR, edad gestacional
- Se cuantificó la prevalencia de prematurez

7.3. Limitaciones

- Algunas variables tienen porcentajes significativos de valores faltantes
- Este es un análisis descriptivo; no establece causalidad
- Se limita a datos de 2024 sin comparación temporal